가설 검정

가설 검정 이야기

- 여러분은 과학자 입니다. 과학자는 새로운 가설을 세우고 이를 검증합니다.
  - 가치 있는 논문으로 인정 받으려면, 어떤 연구를 해야 할까요 ?
    - **기존 발견이나 과학적 결과를 뛰어 넘는, 새로운 연구**를 해야 할 것입니다.
  - 새로운 연구를 위해 먼저 해야 할 일은 **새로운 가설을 수립** 하는 것
  - 그리고 **실험을 통해 결과 데이터를 수집** 합니다.
  - 수집한 데이터로 나의 주장 가설 이 맞다는 것을 입증 해야 합니다. 그리고 기존 입장 가설과 차이나는 데이터가 수집되어야 합니다.
  - 그렇다면 수집한 데이터는 얼마나 차이가 나야 새로운 가설을 채택할 수 있을까?
  - 이를 확인하는 것을 **가설 검정(hypothesis test)**이라고 합니다.

가설 검증 절차

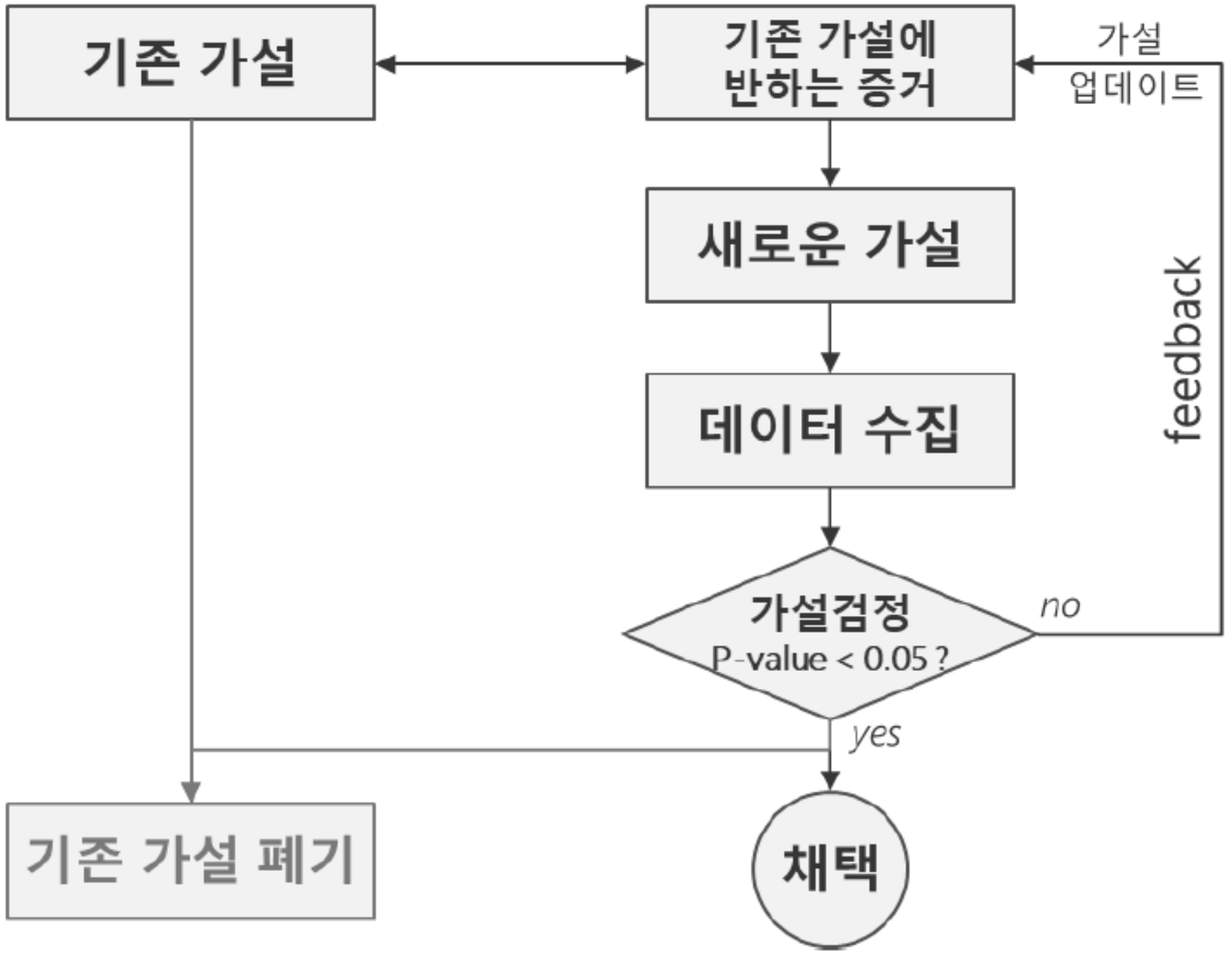
기존 가설
기존 가설에
반하는 증거
가설
업데이트
새로운 가설
데이터 수집
feedback
가설검정
P-value < 0.05 ?
no
yes
기존 가설 폐기
채택

모집단과 표본

- 모집단(Population)과 표본(Sample)
  - 모집단: 우리가 알고 싶은 대상 전체 영역 데이터
  - 표본: 그 대상의 일부 영역 데이터

- 우리는 일부분으로 전체를 추정하고자 합니다.
  - 모집단에 대한 가설을 수립
  - 가설은 보통 x 와 y 의 관계를 표현
    - X에 따라 Y 가 차이가 있습니다.
    - X와 Y는 관계가 있습니다.
  - 표본을 가지고 가설이 진짜 그러한 지 검증(검정) 합니다.

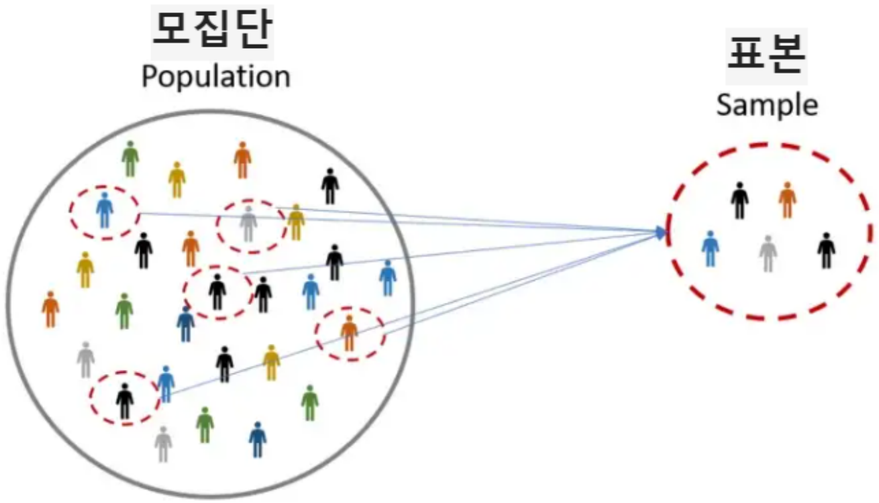

모집단과 표본

- 시험에서 80점을 받았습니다.
  - 시험을 잘 본 것인가요?

- 어떤 정보를 알면 80점이 높은 점수인지 아닌지 알 수 있을까요?
  - 만약 분포를 안다면, 우리는 판단할 수 있습니다.
  - 분포는 우리가 가지고 있는 값에 대해 흔한 결과인지, 드문 결과인지 판단할 수 있게 해줍니다.

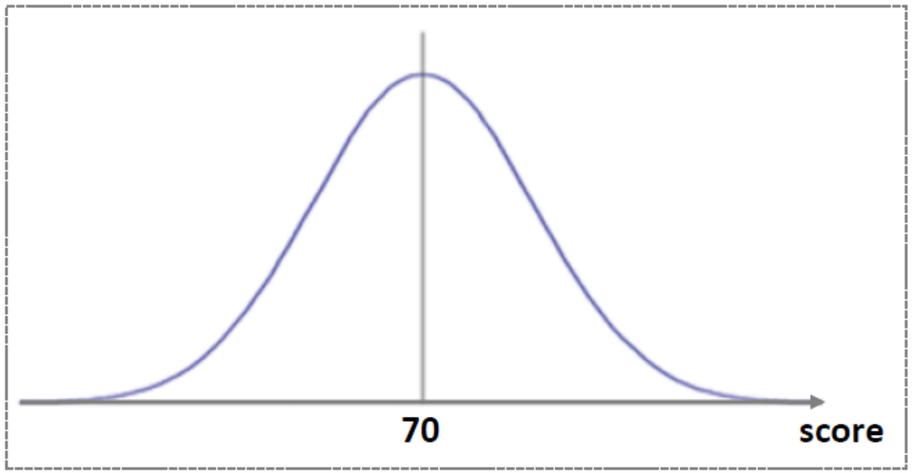

모집단과 표본

- 비즈니스 이해단계에서
  - 비즈니스 문제로부터 우리의 관심사(Y)를 도출하고, Y에 영향을 주는 요인(X)들을 뽑아서 초기 가설을 수립하였습니다.

- 예를 들어,
  - 고객 이탈 예측(y)에 영향을 주는 요인(x)는?
    - 고객의 가입기간(x_1) → 이탈여부(y)
    - 성별(x_2) → 이탈여부(y)
  - 수요량(y)에 영향을 주는 요인(x)는?
    - 기온(x_1) → 수요량(y)
    - 매장지역(x_2) → 수요량(y)

귀무 가설과 대립가설

- 당신의 주장을 귀무가설
  - 현재의 가설
  - 보수적인 입장
  - 영가설

매장지역(x_2)과 수요량(y)은 아무런 관련이 없다.

- 나의 주장을 대립가설
  - 새로운 가설
  - 내가 바라는 바
  - 연구가설

매장지역(x_2) → 수요량(y)

통계적 검정

- 표본으로부터 대립가설을 확인하고 모집단에서도 맞을 것이라 주장합니다.

  ⇒ 통계에서는, 표본 데이터를 바탕으로 **귀무가설을 기각**할 만한 근거가 충분한지 판단합니다.

  - 왜냐하면 가설검정은
    - 대립가설이 참이라고 증명하는 과정이 아니라
    - **귀무가설이 너무 그럴듯하지 않다고 판단할 근거가 있는지** 보는 과정이기 때문입니다.

  - 대립가설 : 매장지역(x2)에 따라 수요량 (y)에 차이가 있습니다.
  - 귀무가설 : 매장지역(x2)에 따라 수요량 (y)에 차이가 없습니다.

통계적 검정

- 표본 데이터를 바탕으로, 귀무가설을 기각할 만한 근거가 충분한지 판단합니다.
  - 대립가설 : 매장지역(x2)에 따라 수요량 (y)에 차이가 있습니다.
  - 귀무가설 : 매장지역(x2)에 따라 수요량 (y)에 차이가 없습니다.

- 차이의 값이 큰지 작은지는 어떻게 판단할 수 있을까?
  - 앞에서 언급한 것처럼 분포를 알면 우리는 판단할 수 있습니다.
  - 만약 분포가 아래와 같을 때, 차이가 8 이라면 큰 것일까?

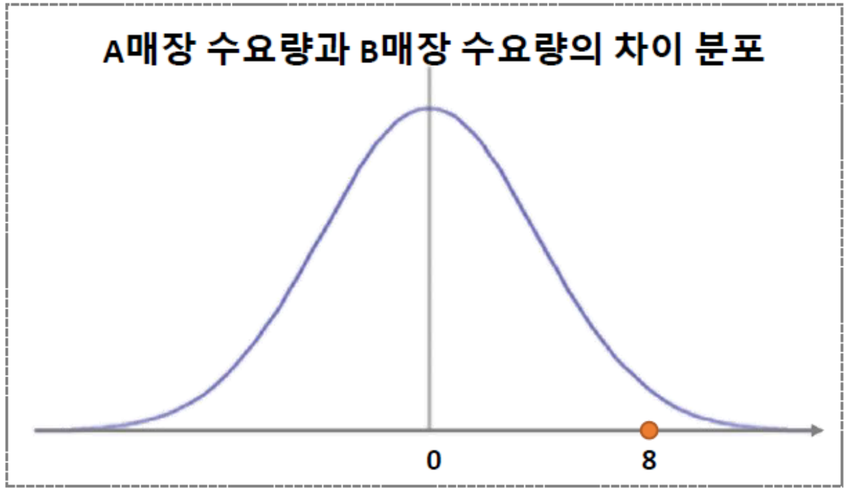

통계적 검정

- 차이 값을 판단하는데 분포와 함께 판단 기준도 필요
  - 차이 값 8로 부터 p-value 를 구할 수 있습니다. 차이 값이 클 수록 p-value 는 작아집니다.
  - 판단기준(유의수준) : 0.05(5%) 혹은 좀더 보수적인 기준으로 0.01(1%) 를 사용
  - 차이가 클 수록 p-value 는 작아집니다. 0.05 보다는 작아야 차이가 있다고 판단 합니다.

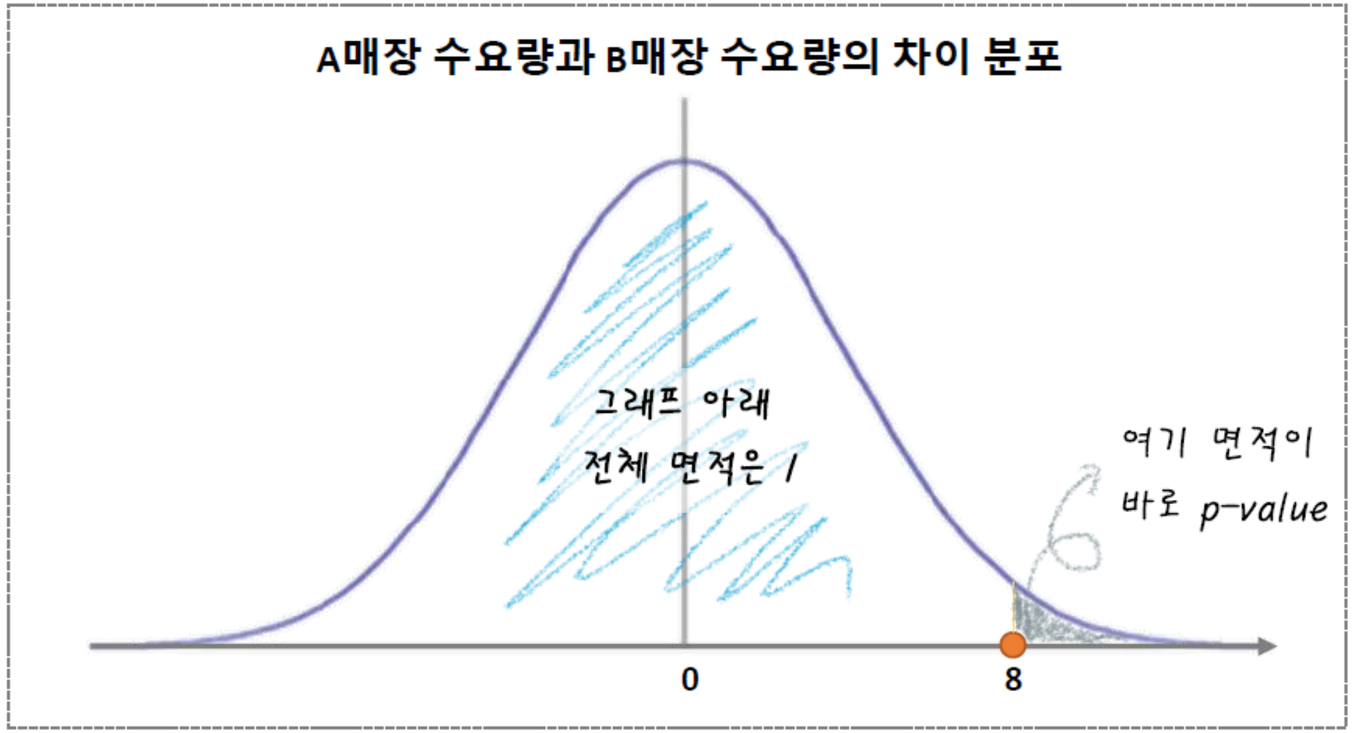

통계적 검정

- 우리의 관심사
  - ① A 매장과 B 매장 중 어디의 수요량이 더 큰지 일 수도 있고
  - ② 매장 간에 수요량의 차이가 있는 것인지 일 수도 있습니다.

① 단측검정

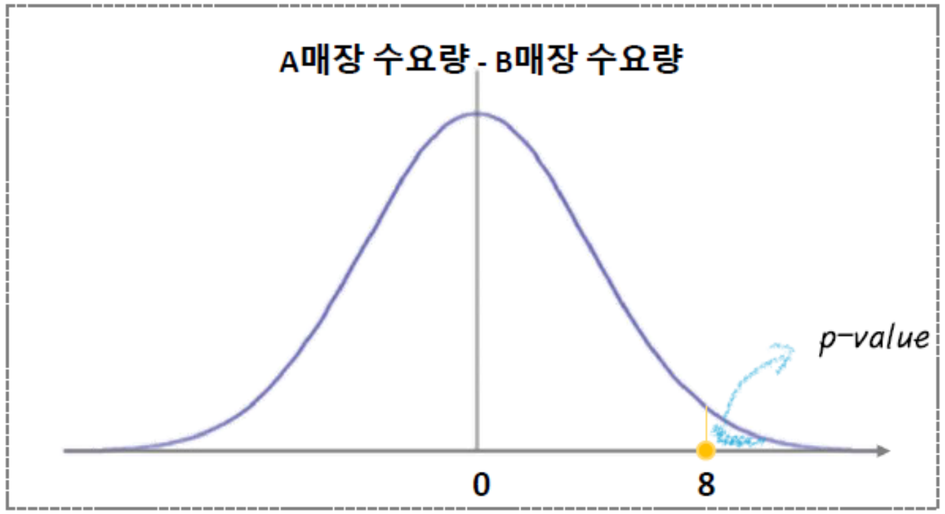

② 양측검정

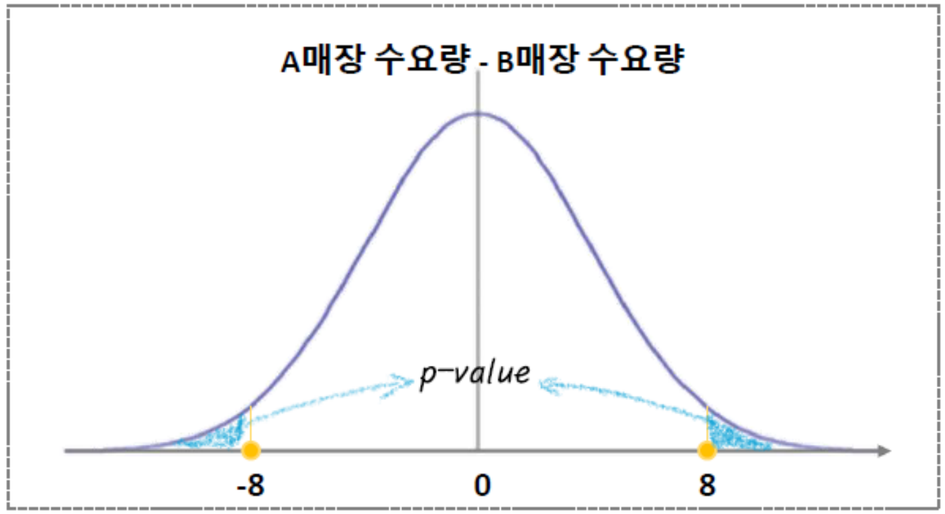

검정 통계량

- 우리는 가설검정을 수행하기 위해 검정 통계량을 계산해 낼 것 (물론 컴퓨터가 해준다!)
  - t 통계량
  - 카이제곱 통계량
  - f 통계량

- 이들은 각각 기준 대비 차이로 계산
  - 계산된 통계량은 각자의 분포를 가집니다.
  - 당연히 분포를 통해서 그 값이(차이가) 큰 지, 작은 지 판단할 수 있습니다.
  - 이를 손쉽게 판단할 수 있도록 계산해 준 것이 p-value 입니다.

가설을 검정한다는 것

- 우리가 세운 가설(대립가설)
  - 오존 농도(공기 오염도)를 예측하고자 할 때,
  - "온도에 따라 오존농도는 달라질 것이다."

- p-value 를 구했더니, 0.001 이라면,
  - 기준(유의수준)으로 정한 5% 보다 작으므로,
  - 우리가 세운 가설이 (모집단에서) 맞을 것이라고 판단할 수 있습니다.

이러한 절차를 가설 검정이라고 한다.